
Metodologia de Calibração e Rastreamento da Bola

Visão computacional para futebol de robôs VSSS

Ideia central. Um modelo robusto, porém caro, aprende com o vídeo e produz referências confiáveis. Depois, um modelo leve é escolhido para se aproximar dessas referências com baixa latência. Quadros difíceis são separados para revisão humana.

Projeto Robot Soccer Vision

Documento conceitual — setembro de 2026

Sumário

1	O problema em poucas palavras	1
2	Calibração inicial	1
2.1	Correção de perspectiva com um quadrilátero	1
2.2	Amostra inicial da bola	1
3	Representação de cor e adaptação à luz	1
4	Pré-processamento comparado	2
5	Técnicas de detecção	3
5.1	Filtro casado disco-menos-anel	3
5.2	Componentes conexos	3
5.3	Transformada de Hough	3
6	O professor robusto	3
7	Autossupervisão e escolha de hiperparâmetros	4
8	Modelo leve e controle de latência	4
8.1	Como e por que medir a latência	5
9	Aprendizado ativo e revisão humana	5
10	Avaliação e interpretação correta	5
11	Resumo visual	6

1 O problema em poucas palavras

A câmera observa o campo por cima e permanece fixa. A bola é laranja, aproximadamente circular e quase não muda de tamanho na imagem. Essas três informações são muito úteis:

- a **cor** reduz a busca às regiões parecidas com laranja;
- a **forma circular** rejeita linhas, etiquetas e manchas;
- o **raio quase constante** elimina objetos grandes ou pequenos demais.

O desafio é que a aparência da cor muda com iluminação, exposição, sombras e reflexos. Além disso, o rastreador precisa responder rapidamente. Por isso, o sistema separa duas funções:

Modelo robusto	Usa várias técnicas e busca consenso. É mais lento e serve como “professor” durante calibração e avaliação.
Modelo leve	Usa apenas a combinação escolhida pelas ablações. É o modelo executado em tempo real durante o jogo.

O modelo robusto não é uma verdade perfeita. Ele é uma **pseudo-referência**. Uma pequena amostra rotulada manualmente continua necessária para detectar erros que os dois modelos possam cometer juntos.

2 Calibração inicial

2.1 Correção de perspectiva com um quadrilátero


O usuário marca os quatro cantos do campo na ordem: superior esquerdo, superior direito, inferior direito e inferior esquerdo. Esses pontos definem um quadrilátero. Uma **homografia** transforma esse quadrilátero em um retângulo, removendo a inclinação aparente causada por uma câmera lateralmente deslocada ou não perfeitamente perpendicular.

O quadrilátero é usado **somente para corrigir o enviesamento da imagem**. Ele não converte pixels em milímetros e não inventa margens fora da região selecionada. O mapa da transformação é calculado uma vez e reutilizado nos demais quadros.

A Figura 1 mostra um exemplo obtido do primeiro quadro de um vídeo de treinamento. À esquerda, os quatro pontos escolhidos delimitam o campo. À direita, a mesma região aparece após a homografia: os cantos passam a formar um retângulo e as áreas externas ao quadrilátero são descartadas.


2.2 Amostra inicial da bola

Na imagem corrigida, o usuário posiciona uma circunferência sobre a bola e ajusta seu raio. Os pixels da parte interna dessa circunferência fornecem a primeira amostra de cor. Usa-se a mediana dos valores, porque ela é menos sensível a um pequeno reflexo branco ou a um pixel com ruído.




3 Representação de cor e adaptação à luz

A imagem é convertida de BGR para **HSV**. Nesse espaço, cada pixel é descrito por:



(a) Antes: quadrilátero selecionado.



(b) Depois: campo retificado.

Figura 1: Correção de perspectiva aplicada ao primeiro quadro do vídeo de treinamento.

- **H (matiz):** o tipo de cor, por exemplo laranja;
- **S (saturação):** quão viva ou acinzentada é a cor;
- **V (valor):** o brilho.

Um pixel entra na máscara de bola quando sua distância para a cor aprendida está dentro das tolerâncias de H, S e V. A matiz é circular: valores próximos das extremidades da escala também podem representar cores vizinhas.

Depois de uma detecção de alta confiança, o sistema observa novamente a parte interna da bola e atualiza a cor por uma **média móvel exponencial**:

$$\text{cor nova} = (1 - \alpha) \text{cor anterior} + \alpha \text{cor observada}.$$

O fator α é a taxa de aprendizagem. Um valor pequeno acompanha mudanças graduais sem reagir demais a um único quadro. A atualização possui travas: exige boa forma circular, boa confiança, saturação mínima e limita a mudança de matiz por quadro. Se a bola não for encontrada, o modelo de cor fica congelado para evitar que o fundo seja aprendido por engano.

4 Pré-processamento comparado

O afinamento testa quatro alternativas. Nenhuma é sempre melhor; a escolha depende do vídeo e do custo medido no computador real.

Alternativa	Intuição e principal compromisso
Sem filtro	Preserva a máscara original e tem custo mínimo, mas é mais sensível a pixels isolados.
Gaussiano 5×5	Suaviza variações locais antes da decisão, porém pode borrar a borda da bola.
Abertura circular	Erosão seguida de dilatação remove pequenos pontos, com risco de reduzir objetos muito pequenos.
Abertura fechamento	+ Além de remover pontos, preenche pequenos buracos causados por reflexo, ao custo de mais operações.

Os elementos morfológicos são elípticos, não quadrados. Isso respeita melhor a geometria da bola e evita introduzir preferência artificial por direções horizontal e vertical.

5 Técnicas de detecção

5.1 Filtro casado disco-menos-anel

O detector leve principal usa uma convolução com um núcleo circular pré-calculado. O centro do núcleo possui pesos positivos e representa a bola. Um anel externo possui pesos negativos e representa o fundo esperado ao redor dela.

Uma bola laranja isolada produz resposta alta: o interior combina com o disco positivo e o entorno não ativa o anel negativo. Uma grande região laranja tende a invadir o anel e perde pontuação.

Como o raio muda pouco, o núcleo é criado uma vez. A convolução procura o ponto de maior resposta. Essa operação é densa, simples e rápida em uma pequena região de busca.

5.2 Componentes conexos

A máscara também pode ser dividida em regiões conectadas. Para cada região, calculam-se área, perímetro, círculo envolvente, circularidade e diferença para o raio esperado. Regiões com tamanho incorreto são descartadas. Essa abordagem é barata quando a máscara contém poucos objetos, mas pode sofrer quando muitas manchas têm a mesma cor.

5.3 Transformada de Hough

O modelo robusto usa ainda a transformada de Hough para círculos. Ela procura evidências de bordas organizadas ao redor de um centro e de um raio. É mais cara, mas fornece uma fonte de evidência diferente da cor preenchida e dos componentes conexos.

6 O professor robusto

O professor executa uma busca global e combina várias opiniões:

1. filtro casado e componentes conexos;
2. três raios próximos ao raio inicial;

3. abertura e fechamento morfológicos;
4. detecção circular por Hough;
5. preferência temporal por posições compatíveis com o movimento recente.

As propostas próximas são agrupadas. Cada grupo recebe votos e uma pontuação de acordo com confiança, concordância espacial e proximidade da posição prevista. Só grupos com consenso mínimo geram uma pseudo-etiqueta. A cor adaptativa do professor também só é atualizada após uma decisão confiável.

Como trabalha fora de tempo real, o professor analisa o vídeo nos dois sentidos. Detecções próximas feitas com passado e futuro são combinadas conforme a confiança; grandes diferenças são rejeitadas. Um suavizador de Kalman bidirecional Rauch–Tung–Striebel ajusta posição e velocidade na trajetória inteira. Lacunas curtas só são preenchidas quando existem posições compatíveis antes e depois, sem inventar dados durante oclusões longas.

Esse conjunto custa mais tempo que o permitido no jogo, mas reduz a chance de confiar em um único tipo de erro. Ele é adequado para processar vídeos gravados fora do laço de controle.

7 Autossupervisão e escolha de hiperparâmetros

Autossupervisão significa criar um sinal de qualidade a partir do próprio vídeo, sem exigir a posição medida por um sensor externo em todos os quadros.

O sistema experimenta variações da cor inicial, raio, tolerâncias HSV, tolerância de raio e taxa de adaptação. Cada candidato é avaliado por quatro sinais:

- **cobertura:** quantos quadros recebem uma detecção;
- **confiança:** quão forte é o consenso interno do professor;
- **ida e volta:** o vídeo processado do início ao fim deve concordar com o mesmo vídeo processado do fim ao início;
- **iluminação:** a posição deve permanecer semelhante após alterações artificiais de brilho e saturação.

O melhor professor produz pseudo-etiquetas bidirecionais. O aluno permanece causal: usa somente o quadro atual e resultados anteriores, nunca o futuro. Comparam-se então 16 combinações: quatro pré-processamentos, dois detectores e busca por região ligada ou desligada. O critério final combina:

$$\text{objetivo} = \text{erro de centro normalizado} + \text{penalidade por falhas} + \text{penalidade por latência}.$$

Esse procedimento seleciona um modelo que não é apenas rápido, nem apenas parecido com o professor: ele procura um equilíbrio entre ambos.

8 Modelo leve e controle de latência

Durante o jogo, o modelo leve usa a velocidade recente para prever onde a bola estará e recorta uma **região de interesse** (ROI). Cor, pré-processamento e detecção são executados apenas nessa região. Se a bola for perdida, o sistema volta temporariamente para uma busca global em meia resolução.

Outras medidas reduzem atraso:

- o núcleo circular é pré-calculado;
- a captura mantém somente o quadro mais novo e descarta quadros antigos;
- o mapa de correção de perspectiva é pré-calculado;
- a interface informa tempo de processamento, latência captura-até-resultado e uso de ROI;
- a cor só se adapta depois de detecções confiáveis.

8.1 Como e por que medir a latência

Uma linha de execução separada, chamada *thread* de captura, recebe cada quadro e registra um instante $t_{captura}$ usando um relógio monotônico. Logo depois da correção de perspectiva e da localização da bola, mas antes de desenhar a interface, registra-se $t_{resultado}$. A medida principal é:

$$L_{captura \rightarrow resultado} = t_{resultado} - t_{captura}.$$

Ela representa aproximadamente há quanto tempo os dados usados para calcular a posição já estavam no computador. A renderização fica fora da medida porque não é necessária para o robô tomar uma decisão e pode ser desativada em produção. A correção de perspectiva fica dentro, pois é indispensável para obter a posição usada pelo controle.

Também se registra o **tempo de processamento**, medido apenas da entrada no pipeline à saída do detector. Ele ajuda a otimizar o algoritmo, mas não substitui a latência completa. Um programa pode processar cada quadro em 2 ms e, ainda assim, entregar uma imagem antiga se ela passou 20 ms esperando em uma fila. Da mesma forma, muitos quadros por segundo medem **vazão**, não garantem que o resultado mais recente chegou cedo. Por isso a captura usa um único slot e substitui quadros antigos pelo mais novo.

O relatório deve apresentar pelo menos média, mediana, percentil 95 e máximo. A média mostra o comportamento comum; o percentil 95 revela atrasos frequentes que a média esconde; o máximo expõe travamentos ocasionais. Nos testes, descartam-se alguns quadros iniciais de aquecimento e mede-se por tempo suficiente para incluir buscas por ROI e recuperações globais.

Sem timestamps fornecidos pela própria câmera, $t_{captura}$ é o instante em que o driver entrega o quadro ao programa. Portanto, essa medida não inclui com precisão exposição e transferência interna da câmera; ela é um limite inferior da latência física total. Quando o SDK da câmera fornecer timestamps de hardware, eles devem substituir esse instante para uma medição ponta a ponta mais fiel.

9 Aprendizado ativo e revisão humana

Rotular todos os quadros é caro e pouco informativo, pois a maioria deles é fácil. O aprendizado ativo calcula uma dificuldade para cada quadro usando:

- baixa confiança e poucos votos do professor;
- diferença entre professor e aluno;
- movimento inesperado em relação à previsão temporal;
- pouca nitidez, medida pela variância do Laplaciano;
- baixo brilho e grande fração de sombras.

Forma-se um conjunto com os quadros mais difíceis e sorteiam-se N exemplos desse conjunto. O sorteio evita revisar apenas um trecho contínuo do vídeo. O usuário pode marcar o centro e o raio ou pular quadros impossíveis por desfoque de movimento, escuridão ou oclusão. O motivo do descarte também é guardado e pode revelar limitações da câmera ou da iluminação.


10 Avaliação e interpretação correta

Na avaliação, professor e aluno recebem exatamente o mesmo quadro corrigido. São registrados erro entre centros, falhas do aluno, detecções exclusivas do aluno, confiança, latência e quadros descartados pela captura. Os resultados agregados incluem média, mediana, percentil 95 e erro máximo, além de concordância relativa ao raio da bola.

Como interpretar: boa concordância com o professor mostra que o aluno preservou o comportamento do modelo robusto. Ela não prova que ambos estão corretos. A validação final deve comparar os dois com uma pequena amostra manual independente.

Para permitir um relatório científico posterior, cada etapa registra caminhos, hashes SHA-256, parâmetros, versões das bibliotecas, revisão Git, resultados por quadro e artefatos gerados. Assim, tabelas e gráficos podem ser reproduzidos sem depender de anotações feitas à mão durante o experimento.

11 Resumo visual



Este documento descreve os princípios da metodologia implementada no projeto Robot Soccer Vision. Ele prioriza intuição e interpretação, não detalhes de código.