
Relatório Comparativo de Calibrações

Tracking da bola no VSSS

Objetivo. Comparar calibrações feitas com iluminação consistente e variável, antes e depois de *active learning*, em dois vídeos de teste independentes. O foco é descobrir qual calibração é mais segura em cada cenário e medir a contribuição das marcações humanas.

Projeto VSSS Vision

23 de setembro de 2026

1 Resumo dos resultados

Recomendação principal. Entre as alternativas avaliadas, a **calibração consistente com *active learning*** é a escolha mais equilibrada para uso geral. No teste consistente ela manteve erro subpixel; no teste variável obteve 92,7% de *recall* e erro médio de 1,44 px, sem os grandes *outliers* observados na calibração variável original.

Para o cenário de luz consistente, a versão **consistente-base** foi ligeiramente melhor: erro médio de 0,61 px e *recall* de 86,7%. O refinamento não trouxe ganho nesse caso. Para o cenário de luz variável, a versão **consistente + *active learning*** foi a opção mais confiável. A calibração variável-base apresentou *recall* alto, mas isso foi enganoso: apenas 45,0% das detecções correspondentes ficaram a menos de meio raio do *teacher*, com erros extremos acima de mil pixels.

O *active learning* teve efeito misto. Ele corrigiu fortemente os grandes erros da calibração variável no teste variável, mas reduziu seu *recall*. Na calibração consistente, o efeito foi pequeno: ajudou a robustez no teste variável, mas não melhorou o teste consistente.

2 Como o experimento foi feito

Foram geradas quatro calibrações:

- vídeo de treino com luz consistente, versão-base e versão com *active learning*;
- vídeo de treino com luz variável, versão-base e versão com *active learning*.

Cada uma foi executada nos dois vídeos de teste, formando oito avaliações. A imagem foi primeiro corrigida pela homografia do quadrilátero do campo. O tracker leve e o *teacher* robusto receberam o mesmo frame retificado. O programa manteve apenas o frame mais recente, descartando frames antigos, como faria no controle em tempo real. Por isso, “frames processados” é menor que o total do vídeo: isso mede comportamento sob carga, e não uma reprodução offline frame a frame.

O vídeo de saída contém somente os frames efetivamente processados e anotados. Assim, sua duração é menor que a do vídeo original; ele serve para inspeção visual das amostras usadas na avaliação. A latência foi medida de captura até resultado, incluindo correção de perspectiva, espera e processamento do tracker leve. O tempo do *teacher* foi registrado separadamente e não representa o custo do sistema em produção.

O que significa cada métrica

<i>Recall</i>	Fração das detecções do <i>teacher</i> também encontradas pelo tracker leve. Maior é melhor.
Erro de centro	Distância entre os centros do tracker leve e do <i>teacher</i> . Menor é melhor.
Dentro de meio raio	Fração das correspondências com erro menor que metade do raio da bola. Ajuda a revelar <i>outliers</i> .
Latência p95	Valor abaixo do qual ficaram 95% das latências de captura até resultado. Menor é melhor.

3 Resultados completos

Treino	Versão	Teste	Frames processados	Recall (%)	Erro médio (px)	Erro p95 (px)	< 0,5r (%)	Latência p95 (ms)
Consistente	Base	Consistente	544	86,68	0,61	1,28	100,00	57,73
Consistente	Active	Consistente	517	86,42	0,73	1,45	100,00	54,12
Variável	Base	Consistente	516	87,87	105,94	1005,14	86,19	58,60
Variável	Active	Consistente	484	86,07	153,56	1070,48	79,95	61,47
Consistente	Base	Variável	724	92,51	2,65	1,77	99,70	56,99
Consistente	Active	Variável	688	92,72	1,44	2,95	99,84	56,79
Variável	Base	Variável	709	96,47	364,74	1095,40	45,03	48,69
Variável	Active	Variável	639	91,24	1,50	2,06	99,66	58,04

Cuidado ao ler apenas o *recall*. A calibração variável-base encontrou a bola com frequência, porém muitas posições estavam no local errado. O erro médio de 364,74 px e o agreement de apenas 45,03% dentro de meio raio mostram que o número alto de detecções não significa tracking correto.

O erro médio maior que o p95 em algumas linhas não é contradição. Poucos erros extremos, próximos de mil pixels, puxam a média para cima, enquanto mais de 95% dos demais valores podem continuar pequenos. Isso é um sinal importante de falha ocasional catastrófica.

4 Contribuição do *active learning*

A calibração consistente recebeu 13 frames positivos rotulados; 17 frames difíceis foram pulados. A calibração variável recebeu 21 positivos; 9 foram pulados. Não houve exemplos manuais negativos (bola ausente), portanto esta rodada avalia principalmente a localização da bola visível, e não a rejeição de falsos positivos quando ela não aparece.

Treino	Teste	Δ recall	Δ erro médio	Interpretação
Consistente	Consistente	-0,26 pp	+0,12 px	Mudança pequena; a versão-base permaneceu melhor.
Consistente	Variável	+0,21 pp	-1,20 px	Ganho de robustez média, mas p95 aumentou 1,18 px.
Variável	Consistente	-1,80 pp	+47,62 px	Piora clara; não usar esta combinação.
Variável	Variável	-5,23 pp	-363,24 px	Removeu erros catastróficos, com perda de detecções.

No treino variável, o *active learning* mudou o *teacher* de HSV (19, 148, 243) e raio 19 para HSV (15, 146, 235) e raio 20. O erro do *teacher* selecionado nos 21 frames manuais foi 0,52 px, com 100% de *recall*. O student continuou usando abertura morfológica, *matched filter* e ROI. Essa pequena mudança de parâmetros foi suficiente para eliminar a maior parte dos saltos de posição no teste variável.

No treino consistente, o *teacher* mudou de raio 17 para 19 e o student passou de nenhum pré-processamento para filtro Gaussiano. Embora o *recall* manual tenha sido 100%, o erro manual selecionado foi 10,92 px. Isso indica que as 13 marcações não foram suficientes para uma melhora segura nesse cenário.

5 Escolha por cenário

Cenário	Calibração indicada	Motivo
Luz consistente	Consistente-base	Melhor erro médio e p95; 100% das correspondências dentro de meio raio.
Luz variável	Consistente + active learning	Melhor equilíbrio entre recall, erro baixo e ausência de falhas catastróficas.
Uso geral / cenário desconhecido	Consistente + active learning	Foi estável nos dois testes e é a opção mais conservadora entre as avaliadas.

6 Limitações e próximo experimento

O *teacher* é uma referência automática, não um *ground truth* independente. Além disso, o refinamento muda o próprio *teacher*; por isso, diferenças pequenas entre base e active não devem ser interpretadas como prova definitiva. Os resultados grandes e consistentes, como a remoção dos erros de aproximadamente mil pixels, são mais confiáveis.

O próximo passo recomendado é rotular manualmente uma pequena amostra estratificada dos **vídeos de teste**, incluindo frames normais, blur, sombras e bola ausente. Essa amostra deve permanecer separada da calibração. Com ela, todas as quatro alternativas podem ser comparadas contra o mesmo *ground truth*, inclusive em falsos positivos.

7 Rastreabilidade

Todos os JSONs de avaliação registram caminho absoluto, SHA-256, comando, versão do Python, OpenCV, commit e estado do repositório. Os vídeos originais usados foram:

- `train_consistent_light.MOV`: 27d7d4468b3a...;
- `train_varying_light.MOV`: 337e034c1acb...;
- `test_consistent_light.MOV`: 1262eaf71cab...;
- `test_varying_light.MOV`: ca08bcba9083....

Os quatro reports de calibração possuem hashes iniciados por 3dc689f033ee, b21854065574, 101a3d0978f7 e 744ebecffb69. O commit de código no início da rodada foi 9aebb003d7035a12215814e76278410ee2f6781a. As cópias MJPEG foram usadas somente porque o OpenCV local não decodificava HEVC; os arquivos originais foram preservados.